Implementando modelos estatísticos de maneira eficiente com o TMB

Um tutorial

Henrique Laureano, Ricardo Petterle & Wagner Bonat

LEG @ UFPR

9 de setembro, 2021

TMB: Template Model Builder

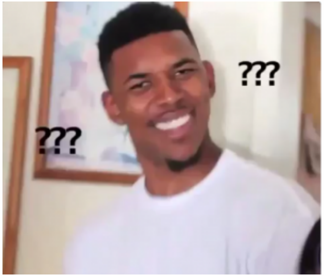

O quê?

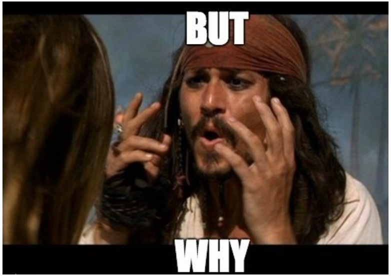

Por quê?

Como?

O que é o Template Model Builder?

Pelas palavras dos autores:

Kristensen et al. (2016).

> *Um pacote R (R Core Team 2021) para a rápida implementação de complexos modelos de efeitos aleatórios através de simples templates C++.*

Complexos modelos de efeitos aleatórios? Do simples ao complicado.

De modelos simples como um

- um modelo linear (**LM**) ou
- um modelo linear generalizado (**GLM**),

até

- **modelos não-lineares com efeitos aleatórios** e
- complexos **modelos espaço-temporais**.

Inúmeras possibilidades...

1. Estudar o efeito de características numa certa variável? **Modelos lineares** (LM);
2. A resposta é não-Normal/Gaussiana? **Modelos lineares generalizados** (GLM);
3. Função não-linear nos parâmetros? **Modelos não-lineares**;
4. Múltiplas respostas/variáveis? **Modelos multivariados**;
5. Presença de dependência não-observada/latente?
   Modelos de efeito aleatório/latente/misto.
   1. Modelos para **dados longitudinais** (medidas repetidas, séries temporais);
   2. Modelos para **dados espaciais** e **espaço-temporais**;
6. ...

O TMB possibilita o ajuste de todos esses modelos.

TMB: Automatic Differentiation and Laplace Approximation

Características-chave:

1. Diferenciação automática;
   o estado-da-arte na computação de derivadas
2. Aproximação de Laplace.
   Uma maneira eficiente de aproximar as integrais do efeito aleatório

Um pouco de matemática para justificar as coisas...

Considere que $f(u, \theta)$ seja o

negativo da sua função de log-verossililhança **conjunta** **nll**),

em que $u \in \mathbb{R}^n$ são os **efeitos aleatórios desconhecidos** e $\theta \in \mathbb{R}^m$ são os **parâmetros.**

Conjunta? Num modelo estatístico especificamos uma distribuição de probabilidade para o que observamos (**dados**) e outra para o que não observamos (**efeito aleatório**). **E é aí que mora o problema**!

Por que usar o TMB?

Paradigmas: Verossimilhancista e Bayesiano.

Bayesiano: Atribuição de distribuições ã *priori* para os parâmetros, que passam a serem vistos como variáveis. Não mais estimamos os "parâmetros", e sim amostramos de sua distribuição a *posteriori*. Funciona, mas é **computacionalmente intensivo**.

Verossimilhancista: Temos um problema, já que o efeito aleatório é **não observável**. Contudo, da estatística básica: se temos uma **conjunta**, basta **integrarmos** na variável que não queremos mais. Resultando numa

Função de verossimilhança **marginal** : $$L(\theta) = \int_{\mathbb{R}^n} \exp(-f(u, \theta))\, du.$$

Bem, essa é a ideia básica. Na prática não é bem assim...

Na prática

Quando a distribuição que especificamos pro **dado** não é Gaussiana,
não conseguimos resolver aquela integral analíticamente.

Aí que entra a **aproximação de Laplace** : $L^{\star}(\theta) = \sqrt{2\pi}^{n} \det(H(\theta))^{-1/2} \exp(-f(\hat{u}, \theta)),$

com

- $H(\theta) = f''_{uu}(\hat{u}(\theta), \theta)$ sendo o Hessiano de $f(u, \theta)$ w.r.t. u e avaliado em $\hat{u}(\theta)$;
- $\hat{u}(\theta) = \arg\min_{u} f(u, \theta)$ sendo o minimizador de $f(u, \theta)$ w.r.t. u.

Finalmente,
a função objetivo final a ser minimizada em termos de θ é

$$-\log L^{\star}(\theta) = -n \log \sqrt{2\pi} + \frac{1}{2} \log \det(H(\theta)) + f(\hat{u}, \theta),$$

i.e., o **log negativo da aproximação de Laplace**.

Automatic Differentiation (AD)

Uncertainty quantification: Método-δ

$$\text{VAR}(\phi(\hat{\theta}) = -\phi'_{\theta}(\hat{\theta}))(\bigtriangledown^2 \log L^{\star}(\hat{\theta}))^{-1}\phi'_{\theta}(\hat{\theta})^{\top},$$

ou seja,
conseguimos quantificar a incerteza da estimativa $\hat{\theta}$, e de qualquer função diferenciável da estimativa $\phi(\hat{\theta})$.

Em todas as etapas

- Aproximação de Laplace (*otimização interna*);
- Log negativo da aproximação de Laplace (*otimização externa*);
- Quantificação da incerteza,

o cálculo de derivadas (1a e 2a ordem) é essencial.
Portanto, sermos capazes de usar a **maneira mais eficiente existente** *hoje* pra calcular essas derivadas, é uma tremenda **qualidade**.

Diferenciação automática (AD) em um exemplo

Considere a função (exemplo tirade de Peyré (2020, página 33))

$$f(x, y) = y \log(x) + \sqrt{y \log(x)}$$

O que a **AD** internamente faz é decompor a função em *nodos*, construir um ***grafo***

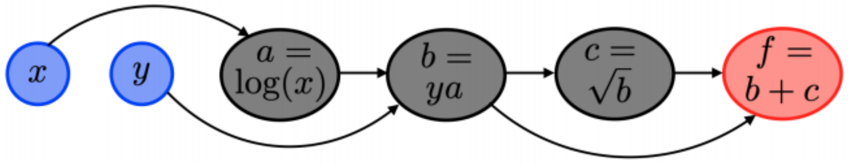

e trabalhar em cima do mesmo.

Existem dois **modos** de avaliar a função via **AD**. O modo **forward** e o modo **reverse**.
O que o **TMB** faz é o **reverse**, **computationalmente mais eficiente**.

AD: modo reverso

Função:

$$f(x,y) = y\log(x) + \sqrt{y\log(x)}$$

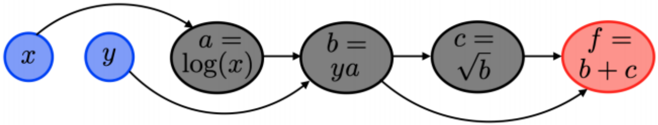

$$\frac{\partial f}{\partial f} = 1$$

$$\frac{\partial f}{\partial c} = \frac{\partial f}{\partial f}\frac{\partial f}{\partial c} = \frac{\partial f}{\partial f}1 \qquad \{c \mapsto f = b + c\}$$

$$\frac{\partial f}{\partial b} = \frac{\partial f}{\partial c}\frac{\partial c}{\partial b} + \frac{\partial f}{\partial f}\frac{\partial f}{\partial b} = \frac{\partial f}{\partial c}\frac{1}{2\sqrt{b}} + \frac{\partial f}{\partial f}1 \qquad \{b \mapsto c = \sqrt{b},\ b \mapsto f = b + c\}$$

$$\frac{\partial f}{\partial a} = \frac{\partial f}{\partial b}\frac{\partial b}{\partial a} = \frac{\partial f}{\partial b}y \qquad \{a \mapsto b = ya\}$$

$$\frac{\partial f}{\partial y} = \frac{\partial f}{\partial b}\frac{\partial b}{\partial y} = \frac{\partial f}{\partial b}a \qquad \{y \mapsto b = ya\}$$

$$\frac{\partial f}{\partial x} = \frac{\partial f}{\partial a}\frac{\partial a}{\partial x} = \frac{\partial f}{\partial a}\frac{1}{x} \qquad \{x \mapsto a = \log(x)\}$$

TMB: Template Model Builder

Como usar?

Workflow

1. Escreva sua função objetivo em um `.cpp` com `#include <TMB.hpp>`;
2. Compile e carregue seu arquivo `.cpp` em R via `TMB::compile()` e `base::dyn.load(TMB::dynlib())`;
3. Compute as derivadas da sua função objetivo com `obj <- TMB::MakeADFun()`;
4. Faça o ajuste do modelo, `opt <- base::nlminb(obj$par, obj$fn, obj$gr)`;
5. Quantifique a incerteza dos parâmetros, `TMB::sdreport(obj)`.

(Extra) Funcionalidades

TMB

Key features:

1. Automatic differentiation;
   The state-of-art in derivatives computation

2. Laplace approximation.
   An efficient fashion to approximate the latent effect integrals

For details about TMB, AD, and Laplace approximation: Laureano (2021).

Ideia de estrutura (slide 1 de 2)

Quatro pontos principais:
o que é, **por quê usar**, **estrutura e características**, e **exemplos**.

1. Explicar em um slide **o que é** o TMB;
2. Tá, mas **por que usar** o TMB?
    1. **Motivação**: modelos mistos;
    2. **Exemplos**: dados longitudinais, modelos multivariados, espaciais (espaço-temporal, talvez pra mostrar quão longe podemos ir);
    3. Não dá pra falar bem dessas coisas sem explicar o que é e qual a estrutura de um **GLM** e de um **GLMM**;
    4. Consequentemente, falar do *calcanhar de Aquiles* dum GLMM: como fazer a **marginalização** de maneira eficiente -> aproximação de Laplace;

Ideia de estrutura (slide 2 de 2)

3. **Estrutura e características** do TMB:
   1. C++;
   2. Bibliotecas eficientes (listar elas) e paralelismo;
   3. **Diferenciação automática**
      (um exemplo, talvez o da minha dissertação);

Referências

Kristensen, K., A. Nielsen, C. W. Berg, H. J. Skaug, and B. M. Bell. 2016. "TMB: Automatic Differentiation and Laplace Approximation." *Journal of Statistical Software* 70 (5): 1–21.

Laureano, H. A. 2021. "Modeling the Cumulative Incidence Function of Clustered Competing Risks Data: A Multinomial Glmm Approach." Master's thesis, Federal University of Paraná (UFPR).

Peyré, G. 2020. "Course Notes on Optimization for Machine Learning." May 10, https://mathematical-tours.github.io/book-sources/optim-ml/OptimML.pdf.

R Core Team. 2021. *R: A Language and Environment for Statistical Computing*. R Foundation for Statistical Computing. Vienna, Austria.